

**CENTRO UNIVERSITÁRIO UNIFECAP**  
**GESTÃO TECNOLOGIA DA INFORMAÇÃO**

Dannyelly Dayane Queiroz

Aplicando Matemática Aplicada para Ciência de Dados em Previsão de Vendas: Um Estudo  
de Caso de Regressão Linear

Taboão da Serra  
SP

DANNYELLY DAYANE QUEIROZ

**Aplicando Matemática Aplicada para Ciência de Dados em Previsão de Vendas: Um Estudo de Caso de Regressão Linear**

Trabalho apresentado como requisito parcial de avaliação da disciplina **Applied Math for Data Science** do Curso de Graduação em **Gestão Tecnologia da Informação** do Centro Universitário UniFECAF.

Tutor(a): **Patricia Miscolcz**

Taboão da Serra  
SP

## LISTA DE FIGURAS

<i>Figura 1- Dados historicos da Wave Surf.....</i>	<i>12</i>
<i>Figura 2- Regressão linear simples no Google Colab.....</i>	<i>13</i>
<i>Figura 3- Regressão linear múltipla no Google Colab.....</i>	<i>15</i>
<i>Figura 4- Lendo dados historicos hipoteticos da Surf Wave .....</i>	<i>21</i>
<i>Figura 5- Ajustando tipo dos dados .....</i>	<i>21</i>
<i>Figura 6 - Uso do describe no dataframe .....</i>	<i>22</i>
<i>Figura 7- Resultado do describe .....</i>	<i>22</i>
<i>Figura 8- Avaliação do modelo predivito .....</i>	<i>23</i>
<i>Figura 9- Codigo de previsão para um novo mês .....</i>	<i>23</i>
<i>Figura 10 - Resultado do codigo de previsão para um novo mês.....</i>	<i>24</i>

## SUMÁRIO

<b>LISTA DE FIGURAS .....</b>	<b>3</b>
<b>1. INTRODUÇÃO .....</b>	<b>5</b>
1.1. Objetivo do trabalho .....	5
1.2. Metodologia Utilizada .....	6
<b>2. CONTEXTUALIZAÇÃO DA SITUAÇÃO-PROBLEMA.....</b>	<b>6</b>
2.1. Descrição da empresa .....	6
2.2. Cenário Geral (O quê, quem, quando, onde e por quê) .....	6
2.3. Importância da Previsão de Vendas.....	6
2.3.1. Por que a Previsão de Vendas é importante? .....	6
<b>3. DETALHAMENTO DO PROBLEMA CENTRAL.....</b>	<b>7</b>
3.1. Dificuldades Atuais da Empresa.....	7
3.1.1. Inconsistência no Estoque .....	7
3.1.2. Planejamento de Produção Ineficiente .....	8
3.1.3. Campanhas de Marketing Ineficazes.....	8
3.1.4. Variações Sazonais Mal Geridas.....	8
3.1.5. Impactos no Gerenciamento de Estoque .....	8
3.1.6. Impactos no Planejamento de Produção.....	8
3.1.7. Impactos nas Campanhas de Marketing.....	9
3.1.8. Influência das Variações Sazonais .....	9
<b>4. LEVANTAMENTO DE FATORES RELEVANTES .....</b>	<b>10</b>
4.1. Principais Partes Afetadas .....	10
4.2. Causas da Imprevisibilidade nas Vendas .....	11
4.2.1. Partes Afetadas pelo Problema.....	11
<b>5. PROPOSTAS DE SOLUÇÕES.....</b>	<b>11</b>
5.1. Modelo de Regressão Linear Simples.....	11
5.1.2. Limitações da regressão linear simples .....	13
5.2. Modelo de Regressão Linear Múltipla.....	14
5.2.1. Limitações da regressão linear múltiplas .....	16
5.3. Machine Learning .....	16
5.3.1. Modelos Machine de learning .....	17
<b>6. DESENVOLVIMENTO DO MODELO PREDITIVO .....</b>	<b>20</b>
5.4. Interpretação dos resultados .....	23
<b>7. IMPLICAÇÕES DA NÃO-RESOLUÇÃO DO PROBLEMA .....</b>	<b>24</b>
7.1. Impactos Financeiros a Longo Prazo.....	24
7.2. Riscos Operacionais e Comerciais.....	24
<b>8. CONCLUSÃO FINAL .....</b>	<b>25</b>
8.1. Síntese dos Resultados Esperados.....	25
8.2. Recomendações á Wave SurfBoards .....	26

<b>9. CONSIDERAÇÕES FINAIS.....</b>	<b>27</b>
REFÊRENCIAS .....	28

## 1. INTRODUÇÃO

A crescente complexidade dos mercados e a necessidade de decisões baseadas em dados têm levado empresas a buscar soluções mais inteligentes e eficientes. Entre os desafios enfrentados pelas organizações, a previsão de vendas é um dos mais relevantes, especialmente em setores com forte oscilação devido à variação sazonal. Nesse contexto, a análise de dados surge como uma grande aliada, sendo uma ferramenta essencial para antecipar demandas, otimizar recursos e orientar estratégias de marketing com maior precisão.

O presente estudo tem como foco a aplicação prática da Matemática Aplicada à Ciência de Dados para desenvolver um modelo preditivo capaz de prever as vendas mensais da empresa fictícia Wave Surfboards, especializada na comercialização de pranchas de surf. A empresa enfrenta dificuldades em antecipar a demanda, o que compromete o planejamento de estoque, a produção e a eficácia de suas campanhas de marketing.

Segundo a Escola Britânica de Artes Criativas e Tecnologia (EBAC), a principal função da ciência de dados é transformar dados, estruturados ou não, em conhecimento útil para uma empresa ou projeto. Dados isolados, desorganizados ou sem análise são apenas informações pontuais.

A proposta envolve a execução de todo o ciclo de análise de dados desde a coleta e organização dos dados históricos, meteorológicos e de marketing, até a aplicação de técnicas de regressão linear. A identificação de padrões e fatores que impactam as vendas permitirá gerar insights valiosos para a tomada de decisões estratégicas.

### 1.1.Objetivo do trabalho

O objetivo deste estudo é desenvolver um modelo preditivo baseado em regressão linear capaz de estimar com maior precisão as vendas mensais da empresa fictícia Wave Surfboards. Para isso, será realizada a aplicação prática de conceitos de matemática aplicada à Ciência de Dados, com ênfase em Álgebra Linear, Cálculo e Estatística.

O modelo será construído a partir da análise de dados históricos de vendas, variáveis climáticas e informações sobre campanhas de marketing, considerando os efeitos sazonais que impactam o desempenho da empresa. Além de prever a demanda com mais assertividade, a solução visa apoiar decisões estratégicas relacionadas ao planejamento de estoque, produção e ações promocionais.

Espera-se que, ao final do estudo de caso, a Wave Surfboards tenha uma ferramenta

confiável e flexível para melhorar sua gestão operacional, reduzir custos e aumentar a satisfação do cliente, promovendo uma atuação mais eficiente e orientada por dados.

## **1.2. Metodologia Utilizada**

A análise se baseia em dados fictícios que simulam o comportamento real do mercado de pranchas de surf. A metodologia adotada envolve o levantamento do problema, análise de dados históricos, aplicação de conceitos matemáticos e estatísticos, construção de modelos preditivos utilizando bibliotecas do Python (NumPy, Pandas e SciPy) e avaliação das soluções propostas.

## **2. CONTEXTUALIZAÇÃO DA SITUAÇÃO-PROBLEMA**

### **2.1. Descrição da empresa**

Ao longo do semestre letivo, com entregas parciais, o cientista de dados, designado a tarefa, deve aplicar os conhecimentos adquiridos na disciplina de matemática aplicada para resolver o problema.

A Wave Surfboards é uma empresa especializada na fabricação e comercialização de pranchas de surf. Possui forte atuação em regiões litorâneas, e depende fortemente de fatores sazonais, como clima e turismo, o que influencia diretamente sua demanda.

### **2.2. Cenário Geral (O quê, quem, quando, onde e por quê)**

Ao longo do semestre letivo, com entregas parciais previamente estabelecidas, o cientista de dados responsável pela tarefa deve aplicar os conhecimentos adquiridos na disciplina de Matemática Aplicada para resolver um problema realista proposto.

A empresa fictícia Wave Surfboards atua no segmento de fabricação e comercialização de pranchas de surf, com forte presença em regiões litorâneas. Seu desempenho comercial é diretamente impactado por fatores sazonais, como clima e fluxo turístico, o que torna a demanda por seus produtos altamente variável.

O projeto consiste no desenvolvimento de um modelo preditivo baseado em regressão linear, com o objetivo de estimar as vendas mensais da empresa. Para isso, serão utilizados dados fictícios que simulam o comportamento real do mercado de pranchas de surf.

### **2.3. Importância da Previsão de Vendas**

#### **2.3.1. Por que a Previsão de Vendas é importante?**

A previsão de vendas torna-se essencial para a Wave Surfboards, pois contribui significativamente para o planejamento estratégico. Antecipar a demanda permite otimizar a gestão de estoque, reduzir desperdícios, melhorar o planejamento da produção e direcionar

campanhas de marketing com maior assertividade.

De acordo com Oliveira, “É importante que a previsão de vendas seja feita com muita cautela, pois ela impacta de modo definitivo em outros departamentos importantes da organização. O gestor deve também considerar questões como uma possível sazonalidade e a própria estabilidade do negócio”

Quando essa previsão é baseada em dados concretos e análises bem estruturadas, ela oferece benefícios como:

- a. Tomada de decisão mais assertiva:** Com projeções confiáveis, a empresa pode planejar investimentos, contratações e ações promocionais com mais segurança.
- b. Redução de riscos:** Antecipar quedas ou picos de vendas ajuda a evitar prejuízos e aproveitar melhor as oportunidades.
- c. Melhor gestão de recursos:** Permite alinhar produção, estoque e logística à demanda prevista, otimizando custos.
- d. Alinhamento estratégico:** Toda a equipe trabalha com foco nos objetivos definidos a partir da previsão, aumentando a eficiência.

Por isso, é fundamental utilizar ferramentas adequadas, dados históricos confiáveis e acompanhar constantemente as variações do mercado.

### **3. DETALHAMENTO DO PROBLEMA CENTRAL**

#### **3.1. Dificuldades Atuais da Empresa**

Atualmente a empresa enfrenta dificuldades significativas na previsão de suas vendas mensais de pranchas de surf, o que compromete diretamente a eficiência do gerenciamento de estoque, o planejamento da produção e a definição de estratégias de marketing. Esses desafios são agravados por diversos fatores, como:

##### **3.1.1. Inconsistência no Estoque**

A ausência de previsões precisas resulta em desequilíbrios no estoque:

- a. Excesso de estoque:** Gera custos adicionais com armazenamento, aumenta o risco de obsolescência dos produtos e pode comprometer o capital de giro da empresa.
- b. Falta de estoque:** Provoca perda de vendas e insatisfação dos clientes, o que



compromete a fidelização e a reputação da marca.

### **3.1.2. Planejamento de Produção Ineficiente**

Sem dados confiáveis de demanda futura o planejamento da produção se torna impreciso, levando a períodos de ociosidade ou sobrecarga de produção. Isso compromete a eficiência operacional, a margem de lucro e a capacidade de resposta ao mercado.

### **3.1.3. Campanhas de Marketing Ineficazes**

A imprevisibilidade nas vendas afeta diretamente a eficácia das ações de marketing. Com campanhas mal direcionadas ou mal temporizadas podem não alcançar o público-alvo no momento adequado. Isso resulta em baixo retorno sobre o investimento e desperdício de recursos financeiros e humanos.

### **3.1.4. Variações Sazonais Mal Geridas**

O mercado de pranchas de surf, em teoria, sofre grande influência de fatores externos, como condições climáticas e eventos locais (campeonatos e temporadas turísticas).

A incapacidade de antecipar essas variações impede ajustes oportunos na produção, no estoque e no marketing, afetando a competitividade da empresa.

### **3.1.5. Impactos no Gerenciamento de Estoque**

Segundo Oliveira:

“Elaborar essa projeção de forma eficiente, o gestor consegue prever quais insumos serão mais necessários em cada período, possibilitando um controle mais eficaz do estoque. Esse planejamento evita o acúmulo excessivo de insumos e produtos prontos, contribuindo para a redução de custos e minimizando desperdícios. Além disso, a previsão de vendas permite que a empresa realize ações de marketing mais eficazes, já que, ao identificar possíveis períodos de baixa demanda, pode organizar promoções e campanhas publicitárias mais agressivas para estimular as vendas.” (OLIVEIRA, p. 125)

No caso da Wave Surfboards, isso significa planejar adequadamente a compra de matérias-primas, garantindo que não haja excesso ou falta desses materiais durante a produção das pranchas. Dessa forma, a empresa reduz custos, evita desperdícios e mantém o fluxo financeiro saudável, especialmente ao promover ações de marketing que estimulam as vendas em períodos de menor demanda.

### **3.1.6. Impactos no Planejamento de Produção**

A ausência de uma previsão de vendas precisa dificulta o planejamento da produção na

Wave Surfboards, ocasionando períodos de ociosidade ou sobrecarga na fabricação das pranchas. Sem dados claros para orientar a produção, a empresa pode produzir em excesso, aumentando custos de armazenamento e desperdícios, ou produzir menos do que a demanda exige, perdendo oportunidades de venda e insatisfazendo clientes. Dessa forma, a falta de planejamento adequado compromete a eficiência operacional e eleva os custos, prejudicando a competitividade e a rentabilidade da Wave Surfboards

### **3.1.7. Impactos nas Campanhas de Marketing**

A ausência de uma previsão de vendas eficaz compromete diretamente a eficiência das campanhas de marketing da Wave Surfboards. Sem dados claros sobre a demanda futura, torna-se difícil planejar ações promocionais estratégicas, definir os períodos mais adequados para divulgação e direcionar os esforços ao público certo. Essa incerteza pode resultar em investimentos mal aproveitados e em uma comunicação desalinhada com os interesses do mercado.

Segundo Oliveira e Lima (2019), o marketing atua nas etapas que antecedem a venda, buscando atrair a atenção e despertar o interesse dos potenciais clientes, enquanto o setor de vendas assume o contato direto, colocando em prática as estratégias planejadas e fortalecendo o relacionamento com o público-alvo.

Os autores reforçam que marketing e vendas não operam de forma isolada: um depende do outro para alcançar os objetivos comerciais da organização.

A falta de previsões confiáveis dificulta o alinhamento entre as campanhas e os períodos de maior impacto no comportamento do consumidor. Sem essa base, ações promocionais podem ser lançadas em momentos inoportunos, com pouco engajamento do público. Isso reduz a efetividade das campanhas, compromete a eficiência da comunicação e pode gerar desperdício de recursos, já que os resultados esperados não se concretizam.

No caso da Wave Surfboards, uma previsão de vendas bem estruturada permite antecipar períodos de baixa demanda, favorecendo a criação de campanhas promocionais mais agressivas e direcionadas. Em contrapartida, nos momentos de alta demanda, as ações podem focar no fortalecimento da marca e na fidelização dos clientes. Dessa forma, o alinhamento entre previsão de vendas, marketing e setor comercial favorece decisões mais assertivas, melhora o desempenho das campanhas e amplia a competitividade da empresa no mercado.

### **3.1.8. Influência das Variações Sazonais**

As variações sazonais exercem forte influência sobre a demanda por produtos e serviços, especialmente em mercados que dependem de fatores climáticos e comportamentais, como é o caso da Wave Surfboards. A procura por pranchas de surfe tende a aumentar durante os meses mais quentes, quando as condições climáticas são favoráveis à prática do esporte e o fluxo de turistas nas regiões litorâneas se intensifica. Já nos períodos de clima mais frio, a demanda costuma cair, exigindo maior atenção no planejamento.

Conforme destacam Oliveira e Lima (2019), “ao identificar variações que podem ter sido influenciadas por fatores sazonais ou cíclicos, a empresa deve considerar esses aspectos na elaboração de suas projeções. A análise dos dados de vendas passadas permite, ainda, observar tendências de mudança no comportamento de compra do público, possibilitando uma adaptação mais eficaz das estratégias comerciais.”

Para a Wave Surfboards, entender essas oscilações é essencial para ajustar corretamente os volumes de produção, o controle de estoque e as ações de marketing ao longo do ano. A antecipação dos efeitos da sazonalidade permite, por exemplo, promover campanhas mais agressivas nos períodos de menor demanda ou preparar estoques suficientes para atender ao pico de vendas com agilidade e qualidade.

Dessa forma, incorporar a análise sazonal na previsão de vendas contribui para um planejamento mais estratégico, reduz riscos e garante maior eficiência na tomada de decisão, impactando positivamente o desempenho da empresa.

### **3.2.LEVANTAMENTO DE FATORES RELEVANTESPrincipais Partes Afetadas**

A dificuldade da Wave Surfboards em prever suas vendas mensais impacta diretamente os seguintes setores:

- a. Gestores e Diretores:** Tomadas de decisão estratégicas ficam comprometidas pela ausência de previsões confiáveis, afetando a definição de metas e alocação de recursos.
- b. Departamento de Produção:** Enfrenta desafios em planejar corretamente a fabricação de pranchas, podendo gerar excesso de produção ou ociosidade de recursos.
- c. Setor de Marketing:** Dificuldade em alinhar campanhas publicitárias com picos e quedas sazonais de vendas, o que reduz a efetividade das ações e aumenta o desperdício de investimento.

- d. Equipe de Estoque e Logística:** Sofre com altos custos de armazenagem ou rupturas de estoque, comprometendo a disponibilidade dos produtos.
- e. Clientes:** Afetados indiretamente pela indisponibilidade de produtos ou pela demora na reposição, o que compromete a experiência do consumidor e a fidelização.
- f. Financeiro:** A incerteza sobre a receita futura dificulta o controle do fluxo de caixa e o planejamento de investimentos.

### **3.3.Causas da Imprevisibilidade nas Vendas**

Entre as principais causas estão a sazonalidade do mercado, que depende fortemente de estações do ano e feriados; variações climáticas, como quedas inesperadas de temperatura; ações de marketing inconsistentes ou mal direcionadas; e a ausência de dados históricos organizados. Além disso, decisões operacionais sem base analítica contribuem para uma falta de previsibilidade, dificultando o planejamento de estoque e campanhas promocionais.

#### **3.3.1. Partes Afetadas pelo Problema**

A imprevisibilidade nas vendas impacta diretamente diferentes áreas da empresa. O setor de estoque enfrenta dificuldades para manter o equilíbrio entre excesso e escassez de pranchas.

O time de marketing tem dificuldades para avaliar o retorno de campanhas. A equipe financeira sofre com a instabilidade no fluxo de caixa, dificultando investimentos. Por fim, a liderança da empresa enfrenta desafios estratégicos ao não contar com dados confiáveis para tomar decisões assertivas.

## **4. PROPOSTAS DE SOLUÇÕES**

Para mitigar esses problemas, temos algumas soluções, sendo cada uma com um custo estimado, seus prós e suas limitações.

### **4.1.Modelo de Regressão Linear Simples**

Usa uma única variável preditora, como o histórico de vendas, para estimar as vendas futuras.

A formula para a regressão simples é  $Y=\beta_0+\beta_1X+\epsilon$

Sendo:

y: o y seria os valores previstos, que queremos fazer uma previsão sobre ele(s);

$x$ : seria a variável independente;

$\beta_0$ : o valor alfa indica o valor de “y”, quando “x” for igual a zero;

$\beta_1$ : seria a variável que determina o quão inclinada a reta será, pois, ela determinará se a relação entre as variáveis é grande ou pequena.

$\epsilon$ : o erro aleatório, representando fatores que afetam o modelo, mas não foram incluídos no modelo (como clima, feriados ou eventos inesperados).

Ou seja, no caso da Wave Surf, usando a regressão simples e considerando apenas a temperatura a formula ficaria:

$$\text{Vendas} = \beta_0 + \beta_1 \times \text{temperatura} + e$$

Para calcular os coeficientes  $\beta_0$  (intercepto) e  $\beta_1$  (inclinação da reta) em um modelo de regressão linear simples, utilizam-se os dados históricos da empresa. Esses dados representam o comportamento passado das variáveis de interesse e servem como base para prever resultados futuros.

Conforme figura 1, observamos os dados históricos da empresa:

*Figura 1- Dados historicos da Wave Surf*

	temperatura_media	investimento_marketing	vendas_mensais
0	25.0	5000	120
1	26.5	5500	135
2	28.0	6000	150
3	29.5	6500	160
4	27.0	6200	145
5	26.0	5800	155
6	25.5	6300	170
7	24.0	6700	180
8	23.5	6400	175
9	22.0	6100	165
10	21.5	5900	155
11	22.5	6000	160

*Fonte 1 – Criação propria*

Como afirma Field (2018):

“Para testar hipóteses, devemos mensurar variáveis. Variáveis são entidades que podem mudar (ou variar); elas podem variar entre diferentes pessoas (p. ex., QI, comportamento), situações (p. ex., desempregado) ou até mesmo pontos no tempo (p. ex., humor, lucro, número de células cancerosas). Muitas hipóteses podem ser expressas em termos de duas variáveis: uma é a causa que propomos, e a outra, um resultado que propomos.”

No contexto da Wave Surfboards, aplicamos isso da seguinte maneira:

A variável independente (X) será, por exemplo, a temperatura média mensal pois o seu valor não depende de outra variável.

A variável dependente (Y) é o número de pranchas vendidas, porque o valor dessa variável depende da variável independente.

Supomos que existe uma relação entre essas variáveis: ou seja, a quantidade de vendas depende da variação da temperatura.

Estimativa dos coeficientes:

Com os dados históricos dessas variáveis (temperatura e vendas), conforme figura 1, e utilizando a biblioteca `sklearn.linear_model` é possível calcular matematicamente os coeficientes  $\beta_0$  e  $\beta_1$ , que representam a equação da reta que melhor se ajusta aos dados.

*Figura 2- Regressão linear simples no Google Colab*

```

1
2 # 5. Modelagem com Regressão Linear Simples
3
4 X = df[["temperatura_media"]]
5 y = df[["vendas_mensais"]]
6
7 modelo = LinearRegression()
8 modelo.fit(X, y)
9
10 # Coeficientes
11 print("Intercepto( $\beta_0$ ):", modelo.intercept_)
12 print("Coeficiente( $\beta_1$ ):", modelo.coef_[0])
13
Intercepto( $\beta_0$ ): 205.44198358467242
Coeficiente( $\beta_1$ ): -1.9777503898234851

```

*Fonte 2 - Criação propria*

Sendo o resultado, conforme figura 2, do intercepto ( $\beta_0$ ) 205.44 e coeficiente ( $\beta_1$ ): -1.97.

Assim, se quiser estimar as vendas em um mês com temperatura média de 25°C, aplicamos:

$$\text{Vendas} = 205.44 - 1.98 \times 25 = 205.44 - 49.44 = 156.0$$

Sendo a previsão de aproximadamente 156 pranchas vendidas.

### 5.1.2. Limitações da regressão linear simples

## 4.2. Modelo de Regressão Linear Múltipla

Como alternativa, a regressão linear múltipla permite considerar duas ou mais variáveis independentes na previsão. Segundo Silva:

“A regressão linear simples resume seus dados em uma reta, tendo uma variável dependente (y) e uma independente (x). Já a regressão linear múltipla também tem seus dados resumidos de forma linear, porém existe ainda uma variável dependente (y) e duas ou mais independentes.”

No contexto da Wave Surf, isso significa que, além da temperatura média, podem ser incluídas variáveis como investimento em marketing e a temperatura, tornando o modelo muito mais preciso.

Sua fórmula é:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

Onde:

Y é a variável dependente, ou seja, o valor que queremos prever (por exemplo, número de pranchas vendidas);

$\beta_0$  é o intercepto, o valor de YYY quando todas as variáveis independentes forem iguais a zero;

$\beta_1$  e  $\beta_2$  são os coeficientes que representam o quanto cada variável  $X_1$  e  $X_2$  impacta o resultado;

$X_1$  e  $X_2$  são variáveis independentes (por exemplo, temperatura média e investimento em marketing);

$\varepsilon$  é o erro aleatório, que representa os fatores não considerados no modelo.

No contexto da Wave Surfboards, aplicamos isso da seguinte maneira:

A variável dependente (Y) será vendas pois esse valor é influenciado por outros fatores e é o que desejamos prever.

As variáveis independentes são:

$X_1$ : a temperatura média mensal, pois seu valor não depende de outras variáveis e pode afetar diretamente o interesse por pranchas de surf;

$X_2$ : o investimento em marketing, que também é uma variável controlável pela empresa e pode influenciar o volume de vendas.

$\varepsilon$  : é o erro, também chamado de resíduo.

A formula ficará:

Figura 3- Regressão linear múltipla no Google Colab

```

1
2# 5. Modelagem com Regressão Linear Múltipla
3
4X = df[["temperatura_media", 'investimento_marketing']]
5y = df["vendas_mensais"]
6
7modelo = LinearRegression()
8modelo.fit(X, y)
9
10# Coeficientes
11print("Intercepto:", modelo.intercept_)
12print("Coeficiente( $\beta_1$ ):", modelo.coef_[0])
13print("Coeficiente( $\beta_2$ ):", modelo.coef_[1])
14
Intercepto: 11.632994750907613
Coeficiente( $\beta_1$ ): -2.257535588420055
Coeficiente( $\beta_2$ ): 0.033286219269385985

```

Fonte 3- Criação do autor

$$\text{Vendas} = \text{Intercepto}(\beta_0) + \beta_1 \times \text{temperatura} + \beta_2 \times \text{investimento\_marketing} + \varepsilon$$

Com base nos dados históricos apresentados na figura 1, utilizando o Google Colab e a biblioteca *sklearn.linear\_model*, obteve-se os seguintes valores para o interceptor e coeficientes do modelo de regressão linear múltipla:

Sendo a formula final:

$$\text{Vendas} = 11,63 - 2,26 \times \text{temperatura} + 0,033 \times \text{investimento\_marketing} + \varepsilon$$

Para ilustrar, suponha que queiramos prever as vendas em um mês com temperatura média de 25°C e investimento em marketing de R\$ 6.000.

Substituindo os valores na fórmula, temos:

$$\text{Vendas} = 11,63 - 2,26 \times 25 + 0,033 \times 6000$$

$$\text{Vendas} = 11,63 - 56,5 + 198 = 153,13$$



Assim, o modelo prevê aproximadamente 153 pranchas vendidas nesse mês.

#### **4.2.1. Limitações da regressão linear múltiplas**

A regressão linear múltipla oferece vantagens importantes para a previsão de vendas na Wave Surfboards, ao considerar várias variáveis independentes simultaneamente. Isso permite um modelo mais completo e preciso em comparação com a regressão simples, além de ainda ser relativamente interpretável para equipes com conhecimento básico em estatística e programação.

Porém, diferentemente da regressão simples, o modelo múltiplo pode demandar mais recursos e conhecimento técnico, elevando os custos de implementação. A necessidade de coleta, limpeza e preparação de múltiplos conjuntos de dados pode exigir um esforço maior da equipe e, dependendo da complexidade, a contratação de especialistas para garantir a qualidade do modelo. Assim, o investimento pode ultrapassar facilmente a faixa de ferramentas gratuitas, chegando a custos médios de implementação, que variam conforme o tamanho da base de dados e a infraestrutura usada.

Além disso, a regressão linear múltipla apresenta limitações importantes, como a suposição de linearidade entre as variáveis e a sensibilidade à correlações, o que pode prejudicar a interpretabilidade do modelo. A presença de outliers continua sendo um desafio, podendo distorcer os coeficientes e gerar previsões imprecisas. O risco de sobreajuste também aumenta, especialmente com muitas variáveis irrelevantes no modelo, comprometendo sua capacidade de generalização.

Portanto, apesar de mais robusta que a regressão simples, a implementação da regressão linear múltipla demanda um esforço maior da equipe de dados e análise, pois envolve a coleta, limpeza e tratamento de múltiplas variáveis, além da validação estatística mais detalhada. Em alguns casos, pode ser necessário investimento em treinamento da equipe ou até a contratação de consultoria externa especializada para garantir a qualidade do modelo.

Embora o processamento computacional continue acessível e possa ser realizado com ferramentas gratuitas como Python e Google Colab, o tempo dedicado aos testes e ajustes do modelo tende a ser mais longo, geralmente em semanas. Esse aumento no tempo e na complexidade se reflete em um custo estimado entre R\$ 1.500 e R\$ 5.000, principalmente relacionado às horas de trabalho da equipe envolvida.

#### **4.3. Machine Learning**

Conforme Martins et al. (2020), “uma premissa fundamental do ramo de Inteligência Artificial (IA) reside no fato de que os sistemas podem aprender com dados, identificar padrões e tomar decisões com mínima interferência humana.” Eles também afirmam que “assim, aplicações de machine learning são projetadas para aprender e melhorar ao longo do tempo, quando expostas a novos dados”.

Além disso, ressaltam que “em geral, um sistema de aprendizado dispõe de um conjunto de dados de treinamento classificados manualmente, com base nos quais o sistema buscará aprender, a partir dos dados de treinamento, como classificar esses dados e como classificar novos dados ainda não observados.”

#### **4.3.1. Modelos Machine de learning**

##### **a. Árvore de Decisão**

Usado para tomar decisões ou fazer previsões a partir de dados. Ela funciona como um "fluxograma" que divide os dados em grupos menores baseados em perguntas ou condições simples, até chegar a uma conclusão ou resultado. Segundo Martins et al. (2020), cada nó interno na árvore equivale a um teste do valor de um dos atributos de entrada,  $A_i$ , e as ramificações dos nós são classificadas com os valores possíveis do atributo,  $A_i = v_{ik}$ . Cada nó de folha na árvore especifica o valor a ser retornado pela função.

Por exemplo, para a Wave podemos prever o volume de vendas mensais de pranchas com base na temperatura e no investimento:

A temperatura média do mês está acima de 25°C?

Não → Previsão de vendas baixas

Sim → Próxima pergunta

O número de turistas no mês é maior que 4.000?

Não → Próxima pergunta

Sim → Próxima pergunta

O investimento em marketing foi superior a R\$ 5.000?

Sim + turistas altos → Previsão de vendas muito altas

Sim + turistas baixos → Previsão de vendas médias (investimento alto, fluxo baixo)

Não + turistas altos → Previsão de vendas médias (investimento baixo, fluxo alto)

Não + turistas baixos → Previsão de vendas baixas (investimento baixo, fluxo baixo)

Conforme acima, o modelo começa avaliando se a temperatura média do mês está acima de 25°C, uma variável que pode aumentar o interesse pelas pranchas devido às condições climáticas favoráveis ao surfe. Se a temperatura for baixa, a previsão é de vendas mais baixas, pois a demanda tende a diminuir.

Caso a temperatura seja alta, o próximo fator analisado é a existência de uma campanha de marketing ativa no mês. Se não houver campanha, a previsão é de vendas médias.

Por fim, o modelo considera o número de turistas no período. Uma maior quantidade de turistas normalmente está associada a um aumento no público potencial e, consequentemente, nas vendas. Se o fluxo turístico for superior a 5.000 pessoas, a previsão é de vendas altas. Caso contrário, as vendas devem se manter em nível médio.

Por exemplo, se em um mês a temperatura for de 30°C, houver campanha de marketing ativa e um fluxo de 5.000 turistas, o modelo irá prever aproximadamente a quantidade de pranchas que serão vendidas, baseado nos dados históricos da empresa.

Essa abordagem facilita a tomada de decisão, permitindo que a Wave Surfboards planeje suas estratégias de vendas e marketing com maior precisão e eficiência.

#### b. Redes neurais

Conforme Silva:

Aliada à inteligência artificial, decorrente do avanço científico em campos como machine learning (o aprendizado de máquinas que substitui a codificação algorítmica por seres humanos) e deep learning (o campo de codificação algorítmica com uso das técnicas de redes neurais artificiais, que imitam o cérebro), (SILVA, F. M.; *et p.18*)

Ou seja, redes neurais são modelos computacionais inspirados no funcionamento do cérebro humano, usados para identificar padrões complexos e fazer previsões a partir de grandes volumes de dados.

No caso da Wave Surfboards, uma rede neural pode prever o volume de vendas mensais de pranchas com base em múltiplas variáveis simultaneamente, como:

- Temperatura média do mês;

- Investimento em marketing;
- Número de turistas;
- Histórico de vendas dos meses anteriores;
- Datas de eventos e campeonatos de surf.

O modelo funciona da seguinte forma:

Cada variável de entrada é recebida pela rede e associada a um peso inicial.

1. Esses valores ponderados são somados e passam por funções de ativação que determinam se a informação será propagada para a próxima camada.
2. A rede possui camadas ocultas que permitem capturar interações complexas entre as variáveis, como o impacto combinado da temperatura alta e do aumento no número de turistas nas vendas.
3. Por fim, a camada de saída gera a previsão do volume de vendas.

Por exemplo, a rede pode aprender que um aumento no investimento em marketing, aliado a um grande evento de surf, tem um efeito multiplicador nas vendas, enquanto que, isoladamente, esse investimento poderia ter impacto menor.

Ao treinar a rede com dados históricos da empresa, o modelo ajusta automaticamente seus parâmetros para melhorar a precisão das previsões. Assim, a Wave Surfboards pode planejar melhor seu estoque e suas ações de marketing, baseando-se em uma análise mais detalhada e dinâmica do mercado.

Essa abordagem permite que a empresa tenha previsões mais robustas e adaptadas a diferentes cenários, facilitando a tomada de decisão e a otimização dos recursos.

Levando isso em consideração, implementar uma solução de machine learning e redes neurais exige um investimento significativo, geralmente entre R\$ 11.000 e R\$ 22.000. Esse valor contempla desde a limpeza e organização dos dados históricos da empresa até o desenvolvimento, treino e validação dos modelos, processos que demandam alta expertise técnica.

Para garantir a eficácia da solução, é fundamental contar com um profissional experiente, como um cientista de dados, capaz de lidar com a complexidade dos algoritmos e a infraestrutura necessária, que inclui aquisição ou aluguel de servidores para processamento e

armazenamento, com custos mensais que podem variar de R\$ 500 a R\$ 2.000, dependendo do volume de dados e do poder computacional requerido.

## **5. DESENVOLVIMENTO DO MODELO PREDITIVO**

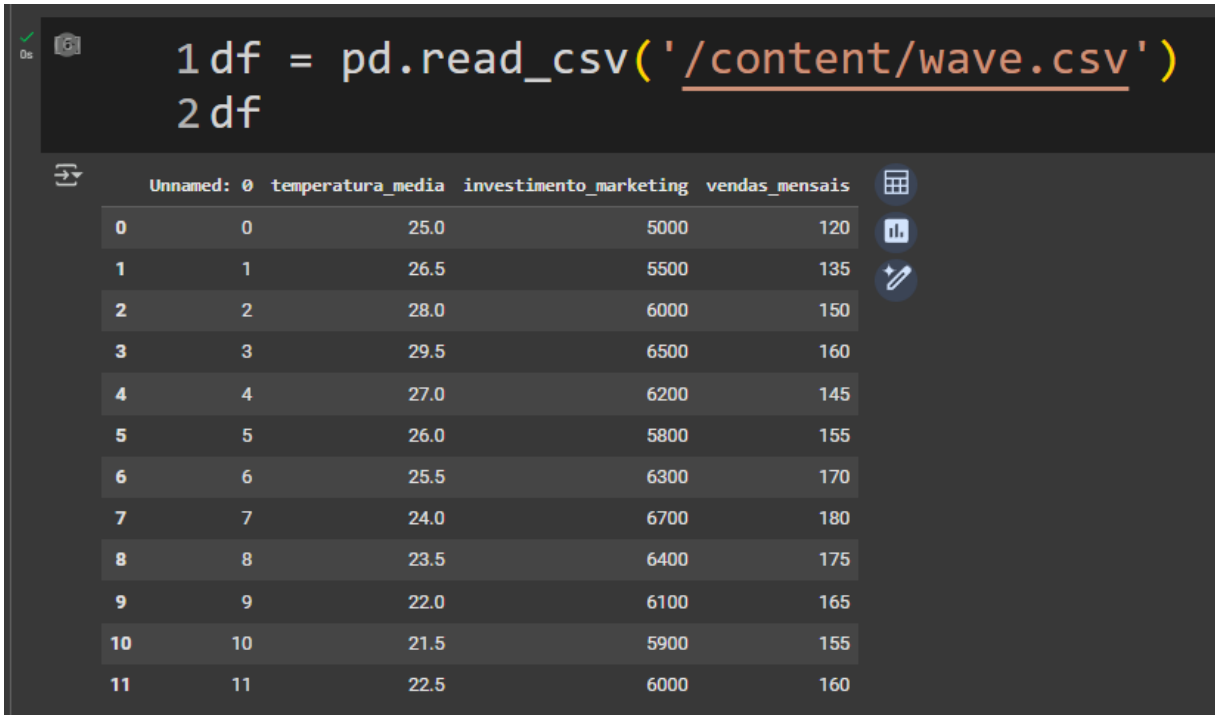
### **a. Preparação dos Dados**

Primeiramente, realizamos uma análise Exploratória de Dados (EDA – Exploratory Data Analysis). De acordo com a IBM (2023), trata-se de uma abordagem utilizada para investigar conjuntos de dados, resumir suas principais características e aplicar técnicas de visualização com o objetivo de facilitar a compreensão das informações. Essa etapa permite identificar padrões, detectar anomalias, testar hipóteses e verificar suposições, contribuindo para uma análise mais aprofundada e embasada dos dados. Além disso, a EDA auxilia na definição das melhores estratégias de manipulação das fontes de dados, possibilitando a extração de insights relevantes e apoiando a construção de modelos preditivos mais eficazes.

Dessa forma, os dados fornecidos pela empresa Wave Surf foram importados para o ambiente Google Colab, onde se iniciou o processo de verificação e análise de seu conteúdo.

Conforme mostrado na figura 4, realizamos a importação dos dados utilizando o ambiente Google Colab, o que nos permitiu trabalhar com Python de forma colaborativa e em nuvem. Utilizamos a biblioteca pandas para carregar o arquivo .csv com as informações históricas de vendas, clima e marketing.

Figura 4- Lendo dados historicos hipoteticos da Surf Wave



```
1 df = pd.read_csv('/content/wave.csv')
2 df
```

	Unnamed: 0	temperatura_media	investimento_marketing	vendas_mensais
0	0	25.0	5000	120
1	1	26.5	5500	135
2	2	28.0	6000	150
3	3	29.5	6500	160
4	4	27.0	6200	145
5	5	26.0	5800	155
6	6	25.5	6300	170
7	7	24.0	6700	180
8	8	23.5	6400	175
9	9	22.0	6100	165
10	10	21.5	5900	155
11	11	22.5	6000	160

Fonte 4 – Criação do autor

### b. Ajuste de Tipos de Dados

Na figura 5, realizamos a conversão dos tipos de dados para garantir que cada coluna fosse tratada corretamente pelo modelo

Figura 5- Ajustando tipo dos dados

```
[109] 1 df['vendas_mensais'] = df['vendas_mensais'].astype(float)
      2 df['investimento_marketing'] = df['investimento_marketing'].astype(float)
      3 df['ano'] = pd.to_datetime(df['ano'])
```

Fonte 5 – Criação do autor

### c. Análise Estatística Descritiva dos Dados

Na figura 6, apresentamos a saída do método describe() aplicado ao dataset, que fornece uma visão geral estatística das principais variáveis utilizadas no modelo.

Na figura 7 temos o resumo que inclui medidas como média, desvio padrão, valores mínimos e máximos, além dos quartis (25%, 50% e 75%).

Essa análise possibilita entender a distribuição dos dados, identificar possíveis outliers e verificar a consistência das informações antes da modelagem. Por exemplo, ao observar a média e o desvio padrão das vendas mensais, podemos ter uma ideia da variação nas vendas ao longo do tempo, o que influencia diretamente no desempenho do modelo preditivo.

Figura 6 - Uso do describe no dataframe

```

1
2 # Análise descritiva
3 display(df[['temperatura_media', 'investimento_marketing', 'vendas_mensais']].describe())
4

```

Fonte 6 - Criação do autor

Figura 7- Resultado do describe

	temperatura_media	investimento_marketing	vendas_mensais
count	12.000000	12.000000	12.000000
mean	25.083333	6033.333333	155.833333
std	2.475639	459.907764	16.899883
min	21.500000	5000.000000	120.000000
25%	23.250000	5875.000000	148.750000
50%	25.250000	6050.000000	157.500000
75%	26.625000	6325.000000	166.250000
max	29.500000	6700.000000	180.000000

Fonte 7 – Criação do autor

#### d. Construção Do Modelo De Regressão Linear

Conforme figura 3, realizamos a separação das variáveis independentes (X) e da variável dependente (Y), ajustamos o modelo de regressão linear múltipla aos dados históricos da empresa fictícia Wave Surfboards e avaliamos os coeficientes  $\beta_0$ ,  $\beta_1$  e  $\beta_2$ , que indicam a influência da temperatura média e do investimento em marketing sobre as vendas mensais.

Figura 8- Avaliação do modelo preditivo

```

1
2 # Avaliação do Modelo
3
4 y_pred = modelo.predict(X)
5 mae = mean_absolute_error(y, y_pred)
6 mse = mean_squared_error(y, y_pred)
7 r2 = r2_score(y, y_pred)
8
9 print(f"Erro Médio Absoluto (MAE): {mae:.2f}")
10 print(f"Erro Quadrático Médio (MSE): {mse:.2f}")
11 print(f"Coeficiente de Determinação (R²): {r2:.3f}")
12

```

Erro Médio Absoluto (MAE): 3.43  
 Erro Quadrático Médio (MSE): 25.45  
 Coeficiente de Determinação (R²): 0.903

Fonte 8 – Criação do autor

Em figura 8, utilizamos métricas como o coeficiente de determinação ( $R^2$ ) e o erro quadrático médio da raiz ( $R^2$ ) para medir a qualidade do ajuste. O  $R^2$  indica a proporção da variação nas vendas explicada pelas variáveis independentes, enquanto o RMSE fornece uma estimativa do erro médio entre os valores reais e previstos.

#### 5.4. Interpretação dos resultados

Com o modelo treinado e validado, tornou-se possível realizar previsões de vendas com base em cenários específicos.

Conforme figura 9, observa-se um exemplo de aplicação prática do modelo de regressão linear múltipla desenvolvido. Considerando um cenário em que a temperatura média do mês é de 25 °C e o investimento em marketing é de R\$ 6.000, o modelo estima (figura 10) a venda de aproximadamente 157 pranchas para esse período, com base nos dados históricos apresentados na figura 1.

Figura 9- Código de previsão para um novo mês

```

20 #Previsão para um novo mês
21 temperatura = 25
22 investimento = 6000
23 venda_prevista = modelo.predict([[temperatura, investimento]])
24 print(f"Previsão de vendas: {venda_prevista[0]:.0f} pranchas")

```

Fonte 9 – Criação do autor



Figura 10 - Resultado do código de previsão para um novo mês

```
Intercepto ( $\beta_0$ ): 45.8441636850099
Coeficientes ( $\beta_1$  e  $\beta_2$ ): [-2.82572084  0.03022351]
Previsão de vendas: 157 pranchas
```

Fonte 10 – Criação do autor

## 6. IMPLICAÇÕES DA NÃO-RESOLUÇÃO DO PROBLEMA

### 6.1. Impactos Financeiros a Longo Prazo

A Wave Surfboards já convive atualmente com a ausência de um modelo preditivo estruturado, o que afeta diretamente sua capacidade de planejar com precisão as vendas e alinhar suas operações. Se essa situação não for resolvida, os impactos financeiros tendem a se intensificar a longo prazo.

A falta de previsibilidade continuará gerando decisões baseadas na intuição, o que pode agravar problemas como:

- a. Desperdício recorrente de recursos com produção desalinhada à demanda, seja por excesso ou por escassez de pranchas.
- b. Investimentos ineficientes em marketing e promoção, aplicados em períodos com baixa propensão de retorno, reduzindo a margem de lucro.
- c. Planejamento financeiro fragilizado, dificultando a alocação de orçamento, investimentos em inovação ou expansão e a negociação com fornecedores.
- d. Crescimento estagnado ou retração, já que a empresa pode deixar de aproveitar picos de demanda ou reagir tardiamente a mudanças no comportamento do consumidor.
- e. Aumento da vulnerabilidade competitiva, visto que concorrentes com inteligência preditiva mais desenvolvida podem operar com maior eficiência e previsibilidade.

Ao longo do tempo, essas consequências podem comprometer a sustentabilidade do negócio, em um cenário mais extremo, a empresa pode entrar em um ciclo de perdas financeiras contínuas, o que, se não for corrigido, pode levar à estagnação total e até mesmo à falência. Portanto, ignorar o problema significa não apenas deixar de crescer, mas também correr o risco real de comprometer a sobrevivência do negócio.

### 6.2. Riscos Operacionais e Comerciais

A ausência de um modelo preditivo eficaz também gera riscos operacionais e comerciais que afetam diretamente a estrutura e a reputação da Wave Surfboards.

Sem previsões confiáveis sobre as vendas, a empresa opera de forma reativa, ou seja, sem capacidade de antecipar demandas, sazonalidades ou mudanças no comportamento do consumidor.

Do ponto de vista operacional, riscos incluem:

- a. Ineficiência na gestão de estoques, levando a excesso de produtos parados ou falta de pranchas em períodos de alta demanda;
- b. Dificuldade no planejamento de produção e logística, com atrasos, custos adicionais e desperdício de recursos;
- c. Sobrecarga da equipe, quando há picos inesperados de demanda, ou subutilização, quando a produção é superestimada.

No aspecto comercial, os riscos são igualmente relevantes:

- a. Perda de competitividade, especialmente frente a empresas que já utilizam inteligência de dados para otimizar decisões de marketing, estoque e preço;
- b. Desalinhamento entre campanhas publicitárias e o comportamento real do mercado, o que pode comprometer o retorno sobre o investimento;
- c. Enfraquecimento da relação com clientes, por não atender às expectativas de disponibilidade, prazo e variedade de produtos a empresa acaba deixando clientes frustrados.

## **7. CONCLUSÃO FINAL**

### **7.1. Síntese dos Resultados Esperados**

Com a implementação do modelo preditivo baseado em regressão linear simples ou múltipla, a Wave Surfboards passa a contar com uma ferramenta analítica capaz de prever com maior precisão suas vendas mensais. Isso proporciona uma mudança significativa na forma como decisões estratégicas são tomadas, saindo de um modelo reativo para um modelo preditivo e orientado por dados.

Entre os principais resultados esperados destacam-se:

- a. Aprimoramento do planejamento de produção, evitando excessos ou faltas de

estoque;

- b. Melhor alocação de recursos de marketing, com base na análise de impacto real sobre as vendas;
- c. Antecipação de cenários desfavoráveis, com possibilidade de ajustes nas estratégias comerciais e operacionais;
- d. Redução de custos operacionais, a partir de previsões mais assertivas centrada em dados;
- e. Aumento na satisfação dos clientes, por meio de maior disponibilidade de produtos em momentos de alta demanda.

Além disso, o modelo oferece flexibilidade para adaptação a novos dados e cenários, permitindo à empresa responder rapidamente a mudanças de mercado, como variações climáticas, sazonalidade ou novos comportamentos do consumidor.

Portanto, a utilização de modelos matemáticos na ciência de dados não apenas contribui para uma gestão mais eficiente, como também fortalece a capacidade competitiva e a sustentabilidade da Wave Surfboards no longo prazo.

## **7.2.Recomendações á Wave SurfBoards**

Com base no estudo e na aplicação do modelo preditivo de regressão linear, apresentamos as seguintes recomendações para a Wave Surfboards, visando mitigar os desafios enfrentados.

### **7.2.1. Implementação Contínua do Modelo Preditivo**

Manter o uso regular do modelo de regressão linear múltipla, levando em consideração, o porte da empresa, e para previsão de vendas mensais, e atualizando-o com novos dados históricos, meteorológicos e de campanhas de marketing. Quanto mais dados, mais eficiente o modelo será. Isso permitirá maior precisão nas previsões e melhor adaptação a variações sazonais e tendências de mercado.

### **7.2.2. Alinhamento do Planejamento de Produção**

Basear a produção nas projeções de vendas, minimizando períodos de ociosidade ou sobrecarga. Assim, a empresa conseguirá aumentar a eficiência produtiva e diminuir custos operacionais.

### **7.2.3. Investimento em Capacitação e Ferramentas de Análise**

Desenvolver as habilidades da equipe para manipulação e interpretação dos dados, bem como investir em ferramentas de análise e visualização, facilitando a tomada de decisão baseada em dados.

### **7.2.4. Cultura Data-Driven**

Incentivar uma cultura organizacional orientada por dados, onde as decisões estratégicas e operacionais sejam suportadas por análises quantitativas e evidências concretas.

Desta forma, a Wave Surfboards poderá mitigar os principais problemas enfrentados, como a inconsistência no estoque, o planejamento inadequado da produção e a baixa efetividade das campanhas de marketing, promovendo uma gestão mais eficiente, redução de custos e aumento da satisfação dos clientes.

## **8. CONSIDERAÇÕES FINAIS**

Este trabalho permitiu aprofundar a aplicação prática de conceitos matemáticos, especialmente álgebra linear e regressão linear, para solucionar um problema real enfrentado pela Wave Surfboards: a previsão das vendas mensais de pranchas de surf. Através da análise dos dados históricos, informações climáticas e campanhas de marketing, foi possível desenvolver um modelo preditivo capaz de auxiliar a empresa a planejar seu estoque, produção e estratégias comerciais de maneira mais eficaz.

Os resultados obtidos evidenciam que a utilização de modelos estatísticos aplicados à ciência de dados pode trazer ganhos significativos na gestão empresarial, reduzindo custos operacionais e melhorando a satisfação do cliente ao garantir a disponibilidade dos produtos no momento certo.

Entretanto, ressalta-se a importância da atualização constante dos dados e do aprimoramento do modelo, para que a Wave Surfboards possa adaptar-se às mudanças do mercado e das variáveis externas que influenciam as vendas. Além disso, recomenda-se que a empresa invista na capacitação da equipe e em ferramentas tecnológicas para fortalecer uma cultura orientada por dados. Atualmente, recomenda-se a adoção da regressão linear múltipla, pois a empresa precisa de um modelo que considere mais de uma variável independente. Como fatores como temperatura média e investimento em marketing influenciam simultaneamente as vendas, a regressão linear simples torna-se insuficiente. A regressão múltipla, por sua vez, oferece uma abordagem mais adequada à complexidade do cenário, permitindo previsões mais

precisas. Além disso, essa técnica possui um custo de implementação consideravelmente menor se comparado aos modelos baseados em machine learning e redes neurais, o que a torna uma alternativa mais viável para a Wave Surfs.

Por fim, este estudo reforça o potencial da matemática aplicada e da ciência de dados como ferramentas estratégicas para a tomada de decisões nas empresas, incentivando a continuidade de pesquisas e o desenvolvimento de soluções cada vez mais precisas com dados.

## REFÊRENCIAS

EBAC. **Tudo sobre ciência de dados.** Disponível em: <https://ebaonline.com.br/blog/tudo-sobre-ciencia-de-dados>. Acesso em: 1 jul. 2025.

FIELD, Andy. **Descobrimdo a estatística usando o SPSS.** 5. ed. Porto Alegre: Penso, 2020.

IBM. **Exploratory Data Analysis.** Disponível em: <https://www.ibm.com/br-pt/think/topics/exploratory-data-analysis>. Acesso em: 1 jul. 2025.

MARTINS, Julio Serafim et al. **Processamentos de Linguagem Natural.** 1. ed. Porto Alegre: Sagah, 2020. 285 p.

SILVA, C. et al. **Métodos estatísticos.** Porto Alegre: SAGAH, 2021.

STERLING, Mary Jayne. **Álgebra 1 para leigos.** Rio de Janeiro: Alta Books, 2011.

OLIVEIRA, C. K.; LIMA, A. P. L. **Gestão de vendas e negociação.** Porto Alegre: Sagah, 2019.

CHEI, Flávia. **Introdução aos modelos de regressão linear.** Brasília, DF: Enap, 2019.